

Entrega Final da Ideia — Assistente de Prontuário Automático

Programa AI Glasses Brasil 2026 · Trilha: Bem-Estar Documento estruturado (Seção A) — 19/08/2026
Diagrama de arquitetura (Seção B): `arquitetura.png` / `arquitetura.mmd`

A.1 Problema

Médicos brasileiros gastam parcela significativa da consulta **documentando em vez de atendendo**: estudos internacionais apontam até 2 horas de trabalho burocrático para cada hora de contato com paciente, e a digitação durante o atendimento divide a atenção do profissional, degrada a relação médico-paciente e produz prontuários incompletos — com consequências clínicas (informação perdida), legais (registro frágil em disputas) e humanas (burnout documental).

O problema tem três camadas que atacamos juntas:

1. **Tempo**: a documentação compete com o atendimento.
2. **Qualidade do registro**: o que não é anotado na hora se perde ou é reconstruído de memória.
3. **Proteção médico-legal**: o profissional raramente tem evidência íntegra e auditável do que foi dito e feito na consulta.

A.2 Usuário-alvo

Primário: médico(a) de consultório/ambatório em consultas eletivas (clínica geral, dermatologia, ortopedia — especialidades com exame visual se beneficiam da foto contextual). Ele veste os óculos, conduz a consulta normalmente e não toca em tela durante o atendimento.

Secundários: paciente (beneficiado pela atenção integral e pelo consentimento transparente) e instituição de saúde (controladora dos dados, beneficiada por registros completos, auditáveis e conformes à LGPD).

A.3 Walkthrough de uso

Fluxo principal

1. **Preparo (30s, única interação com o celular)**: médico abre o companion, confere seu perfil (nome/CRM), digita o nome do paciente e registra os consentimentos — paciente, acompanhante (se presente) e, separadamente, autorização de CID em atestado. **Sem consentimento do paciente, o app se recusa a iniciar** (bloqueio em código).
2. Médico toca "Iniciar consulta", **guarda o celular** (tela pode ser bloqueada — a captura roda em Foreground Service com notificação persistente e neutra).
3. A consulta acontece **naturalmente**: o áudio flui dos óculos por Bluetooth HFP e é transcrito em tempo real no telefone (Vosk PT-BR, on-device), com timestamp por palavra.
4. Ao examinar uma lesão, o médico diz **"registrar imagem"** → a câmera dos óculos é ativada por poucos segundos e captura uma foto pontual (`capturePhoto()` do DAT durante um burst breve de stream), cifrada e vinculada à consulta → resposta por áudio: *"Imagem registrada"*.
5. Ao definir a conduta, diz **"emitir atestado de três dias"** → *"Atestado anotado"*.
6. Diz **"encerrar consulta"** → o telefone estrutura a transcrição em fatos com proveniência → rascunho SOAP → validação anti-alucinação → resposta por áudio: *"Consulta encerrada. Rascunho pronto com N fatos, X para revisar. Atestado de 3 dias aguardando revisão."*

7. **Entre consultas**, o médico abre a tela de revisão: vê S/O/A/P com cada fato apontando para o trecho do áudio ([20s–40s]), fatos incertos marcados, e o rascunho do atestado. **Edita, confirma ou descarta**. Só após a confirmação o rascunho vira base do registro oficial e o atestado vira PDF (com hash auditado; assinatura física do médico — ICP-Brasil na fase 2).

Fluxos de exceção

Exceção	Comportamento
Paciente recusa	Captura não inicia; consulta segue normal sem o app
Óculos com bateria baixa / aquecimento	Escada de degradação automática L0→L4 : reduz fps → encerra vídeo → remove câmera → por último cai para o mic do celular. Áudio clínico é o último a morrer; cada transição é anunciada por áudio
Óculos desconectam no meio	Fallback imediato para o microfone do celular (L4) — a consulta não é perdida
App morre (crash/OEM)	Perda máxima de 60s (chunks selados a cada minuto); a lacuna fica documentada no manifesto (gap de sequência) — juridicamente melhor que um registro "editado"; temporários órfãos são descartados
ASR incerto / termo não reconhecido	Fato marcado " incerto " ou campo " não informado " — o sistema nunca completa lacunas (testado: quando o ASR destruiu o CID falado, o atestado saiu corretamente sem CID)
Paciente pede exclusão (LGPD art. 18)	"Descartar consulta" apaga tudo; vídeo de segurança tem crypto-erasure (destruição das chaves torna o conteúdo irrecuperável sem precisar decifrá-lo)

A.4 Decisões técnicas (justificativa + alternativas descartadas)

#	Decisão	Justificativa	Alternativas descartadas
1	Áudio via Bluetooth HFP/SCO do Android (setCommunicationDevice), não pelo SDK	O DAT 0.9 não expõe microfone como API pública ; a própria documentação da Meta define o caminho suportado: sessões DAT "compartilham microfone e alto-falante com o stack Bluetooth do sistema", com guia oficial de ordenação (rota HFP estabilizada antes de iniciar o stream) — exatamente a ordem que implementamos	Esperar API de áudio do DAT (não existe); usar só o mic do celular (perde o mãos-livres — mantido apenas como fallback L4)
2	IA 100% on-device (ASR Vosk + pipeline no telefone)	Dado de saúde é sensível (LGPD art. 5º II, art. 11): zero conteúdo clínico em rede elimina a maior superfície de risco; funciona sem internet;	ASR/LLM em nuvem (Whisper API, GPT): transferência de dado sensível, dependência de rede, custo por consulta,

		latência previsível; demo em modo avião	impossível demonstrar minimização equivalente
3	Câmera como evento: burst breve de stream + <code>capturePhoto()</code> por voz, sem stream contínuo como padrão	A captura de foto do DAT ocorre durante um stream ativo; ativamos o stream por poucos segundos apenas no comando de voz. Stream contínuo é evitado porque a coexistência HFP+stream varia por aparelho (issue pública #136: há handset validado com 5,5 min estáveis e handset com timeouts de GATT) e drena bateria	Vídeo contínuo como padrão (rejeitado pela análise LGPD de necessidade e pela AUP; sobrevive apenas como modo blindado opcional , desligado por padrão)
4	Pipeline em 2 estágios: extração factual → classificação SOAP , com proveniência obrigatória por fato e validador de alucinação (unsupported-statement-rate)	Reduz a liberdade generativa a zero no MVP: fato sem origem no áudio não compila (invariante no modelo de dados); a métrica torna a alucinação mensurável	"LLM escreve o prontuário" em um passo (alucinação não mensurável, inaceitável em documento clínico)
5	Classificador heurístico agora; LLM local (Gemma 3n) na fase 2 atrás da mesma interface	Heurística tem zero alucinação por construção e roda em qualquer aparelho; a interface FactExtractor permite trocar pelo LLM após benchmark de RAM/latência no hardware real	Muse Glimmer on-device (30B ≈ 17–20 GB — não cabe em smartphone; avaliado e descartado); LLM em nuvem (decisão #2)
6	Cofre por envelope: DEK AES-GCM por chunk de 60s, KEK no Android Keystore; AAD amarra chunk à consulta	Perda máxima de 60s em falha; chunk não pode ser transplantado entre consultas (verificado por teste criptográfico); chave-mestra não exportável	Cifrar o arquivo inteiro no fim (perde tudo em crash); armazenar em servidor próprio (reintroduz nuvem)
7	Modo blindado do vídeo (opcional): DEK embrulhada somente na chave pública do custodiante institucional; abertura só com a chave privada, mediante ordem judicial	Proteção médico-legal com garantia técnica: nem o médico consegue assistir (validado ponta a ponta: decifra externa com a chave do custodiante funciona; local é impossível). Sem chave configurada, vídeo não grava	Vídeo decifrável no aparelho (risco de uso indevido); gravação sem consentimento específico (vetado pela análise LGPD)
8	Foreground Service <code>microphone connectedDevice</code> , iniciado com Activity visível	Exigência do Android 14+ para FGS de microfone; sobrevive a tela bloqueada/background (testado)	WorkManager/serviço comum (morto pelo sistema); manter Activity aberta (péssima UX mãos-livres)

9	Desenvolvimento contra gateway próprio (DeviceGateway) + MockDeviceKit	Hardware real só existe no dia do hackathon; a abstração isola o SDK em preview (que muda a cada versão) e permitiu validar todo o pipeline em emulador antes de tocar nos óculos	Desenvolver direto contra o DAT só no dia (risco integral concentrado em 1 dia)
10	SOAP como estrutura operacional; FHIR como camada futura	SOAP é o padrão cognitivo do médico brasileiro; FHIR entra na integração com sistemas (fase 2) sem retrabalho do modelo	FHIR nativo desde o MVP (complexidade sem valor demonstrável no hackathon)
11	Atestado por voz com guardrails CFM (Res. 1.658/2002): dias/CID nunca inferidos; CID exige consentimento específico; documento só após confirmação	Mesmo princípio anti-alucinação aplicado a documento legal; testado com ASR degradado (extrai dias corretos e recusou-se a inventar CID)	Receita médica no MVP (regulação de prescrição eletrônica exige assinatura qualificada — fica como roadmap)

A.5 Concorrentes e diferenciação

Concorrente	O que faz	Por que somos diferentes
Nuance DAX Copilot (Microsoft)	Ambient scribe líder global; grava a consulta pelo celular/sala e gera nota clínica na nuvem Azure	Nuvem (dado sai do consultório), inglês-primeiro, custo de assinatura alto, sem mãos-livres real nem captura visual
Abridge / Suki	Scribes ambient por app de celular, nuvem	Mesmas limitações: nuvem + telefone sobre a mesa; nenhum usa o ponto de vista do médico
Amazon HealthScribe	API de transcrição/sumarização clínica (AWS)	É infraestrutura de nuvem para terceiros — o oposto do nosso desenho de minimização
Voa Health (Brasil)	Scribe ambient PT-BR via celular, processamento em nuvem	PT-BR nativo como nós, mas nuvem e sem hardware vestível
Prontuários eletrônicos BR (iClinic, Feegow etc.)	Registro manual/dictation	Não resolvem a captura ambient; são o destino futuro da nossa exportação (FHIR)

Nossa combinação é inédita: (1) óculos = mãos 100% livres + câmera no ponto de vista do médico; (2) **zero nuvem** — único da categoria demonstrável em modo avião; (3) rastreabilidade fato-a-fato com métrica de alucinação; (4) modo blindado com garantia criptográfica para proteção médico-legal; (5) atestado por comando de voz com guardrails do CFM.

A.6 Os cinco pilares técnicos obrigatórios

1. Uso de IA (funcional e comprovável)

ASR streaming PT-BR on-device (Vosk, timestamps por palavra) + pipeline de estruturação clínica: extração factual → classificação SOAP → **validador de proveniência** que mede o percentual de afirmações sem suporte na transcrição (no protótipo: **0%**). Detecção de comandos de voz sobre os parciais do ASR. Fase 2: LLM local (Gemma 3n via AI Edge) atrás da mesma interface, com a mesma métrica de aceitação. *Comprovável: o protótipo já executa tudo isso em emulador Android, com consulta simulada de ponta a ponta.*

2. Câmera ou microfone como entrada principal

Microfone dos óculos é o canal primário — pelo caminho definido na documentação oficial da Meta ("Use device microphones and speakers"): HFP pelo stack Bluetooth do sistema, com o nosso código de rota idêntico ao exemplo oficial Android (`MODE_IN_COMMUNICATION` + `setCommunicationDevice(TYPE_BLUETOOTH_SCO)`), áudio 8 kHz mono conforme a spec, e a ordenação oficial respeitada (rota estabilizada antes do stream). Ressalva honesta que vamos testar no hackathon: em HFP o beamforming dos óculos prioriza a voz de quem os veste — se a voz do paciente chegar fraca, o desenho prevê o mic do telefone como captura de sala (nível L4 da escada, já implementado), mantendo óculos para TTS e câmera. **Câmera** via DAT 0.9 (`DeviceSession.addCamera` → burst breve de stream + `capturePhoto()`) acionada por comando de voz para evidência visual pontual — desenho deliberado de "câmera como evento" pelas limitações verificadas do stream (resolução 720p máx., FOV ~53°, coexistência com HFP dependente do aparelho).

3. Saída por áudio

Toda a interação durante a consulta é falada (TTS PT-BR): confirmações curtas ("*Imagem registrada*", "*Atestado anotado*"), avisos da escada de energia ("*Modo de economia nível L2*"), fallbacks ("*Óculos não encontrados, usando microfone do telefone*") e o resumo final com pendências. Desenho não-intrusivo: frases de 1 linha, nunca áudio contínuo.

4. Privacidade e dados

Dado de saúde = sensível (LGPD art. 5º, II; art. 11 — base legal: tutela da saúde + consentimento destacado como salvaguarda). Medidas implementadas: consentimento **bloqueante** (paciente, acompanhante e CID separados); processamento 100% local — **o app sequer declara a permissão INTERNET no manifest**, sendo incapaz de rede por construção (demonstrável em modo avião); cifra AES-GCM por chunk com chave no Keystore; telemetria e crash-reporting do SDK **desligados** (`ANALYTICS_OPT_OUT` , `CRASH_REPORTING_OPT_OUT`); notificação persistente sem conteúdo clínico; auditoria append-only hash-encadeada (adulteração detectável); revisão humana obrigatória antes de qualquer registro; direito de eliminação por descarte total e **crypto-erasure**; vídeo de segurança (opcional, OFF por padrão) indecifrável no aparelho — só custodiante institucional com ordem judicial.

5. Eficiência de bateria

Estratégia em três frentes, instrumentada: (a) **os óculos só trabalham quando necessário** — mic contínuo é inevitável (é o produto), mas câmera é por evento e vídeo opcional roda a 360p@7fps; (b) **escada de degradação L0→L4** dirigida pelos erros tipados do DAT (`BATTERY_CRITICAL` , `PEAK_POWER_SHUTDOWN` , `THERMAL_*`) e nível térmico — degrada vídeo → câmera → rota BT, preservando o áudio clínico; (c) **IA pesada roda no telefone**, nunca nos óculos, e a estruturação ocorre uma única vez ao encerrar (não em

tempo real). Telemetria de bateria do telefone é auditada por consulta; a curva de consumo dos óculos por perfil será medida no hardware real (protocolo pronto).

Status de validação (transparência técnica)

Validado em protótipo funcional (emulador + 52 testes automatizados)	Pendente de hardware real (protocolo pronto)
Pipeline completo fala→SOAP→cofre→revisão; foto e atestado por voz; modo blindado com decifra externa; escada de energia; background/tela bloqueada; recuperação de crash; consentimento bloqueante	Captura do mic dos óculos via HFP — nosso código é idêntico ao exemplo oficial da documentação da Meta, mas só validaremos nós mesmos no hardware; beamforming em HFP prioriza a voz do médico (docs oficiais) — medir a captação do paciente e, se preciso, usar o mic do telefone como captura de sala (fallback já implementado); coexistência HFP+câmera no aparelho fornecido (go/no-go na 1ª hora); curva de bateria dos óculos; ASR com HFP real (piso 8 kHz já medido em simulação = spec oficial); FOV de enquadramento