

Entrega Final da Ideia — Assistente de Prontuário Automático

Programa AI Glasses Brasil 2026 · Trilha: Bem-Estar Documento estruturado (Seção A) — 19/08/2026
Diagrama de arquitetura (Seção B): `arquitetura.png` / `arquitetura.mmd`

Resumo executivo. O médico veste os Ray-Ban Meta, atende normalmente e dita por voz fotos clínicas e atestados; o celular transforma a consulta em rascunho de prontuário SOAP com rastreabilidade fato-a-fato — **100% on-device, sem nuvem** (o app nem declara permissão de INTERNET). O médico revisa e confirma; nada é registrado sem ele. **Já roda hoje:** pipeline completo validado em emulador Android com 52 testes automatizados (fala→SOAP→cofre cifrado→revisão→PDF de atestado). **Falta validar em hardware real** (protocolo pronto para a 1ª hora do hackathon): mic dos óculos via HFP, coexistência com câmera e bateria. Diferencial contra DAX/Abridge/HealthScribe: único demonstrável em modo avião, com ponto de vista do médico e proteção médico-legal criptográfica.

A.1 Problema e impacto

Médicos gastam parcela significativa da consulta **documentando em vez de atendendo**: o estudo de referência (Sinsky et al., *Annals of Internal Medicine*, 2016) mediu ~2 horas de trabalho em prontuário/burocracia para cada 1 hora de contato clínico. A digitação durante o atendimento divide a atenção, degrada a relação médico-paciente e produz prontuários incompletos — com consequências clínicas (informação perdida), legais (registro frágil em disputas) e humanas (burnout documental).

O problema tem três camadas que atacamos juntas:

- 1. **Tempo:** a documentação compete com o atendimento.
- 2. **Qualidade do registro:** o que não é anotado na hora se perde ou é reconstruído de memória.
- 3. **Proteção médico-legal:** o profissional raramente tem evidência íntegra e auditável do que foi dito e feito.

Impacto quantificado (estimativa com premissas explícitas, a validar em piloto):

Premissa	Valor	Fonte/base
Médicos ativos no Brasil	~575 mil	Demografia Médica CFM/USP 2024
Documentação embutida numa consulta de 20 min	~5–7 min	Proporção do achado de Sinsky et al.
Tempo devolvido por consulta (rascunho pronto + revisão rápida)	~4–5 min	Revisão alvo ≤ 2 min (≤10% da consulta)
Ganho por médico (16 consultas/turno)	~65–80 min/dia ≈ 25h/mês	Cálculo direto

Métricas de sucesso definidas: tempo de documentação por consulta (antes/depois), tempo de revisão ≤ 10% da duração da consulta, completude do prontuário (campos preenchidos com proveniência) e adoção (consultas capturadas/dia).

A.2 Usuário-alvo

Primário: médico(a) de consultório/ambulatório em consultas eletivas (clínica geral, dermatologia, ortopedia — especialidades com exame visual se beneficiam da foto contextual). Ele veste os óculos, conduz a consulta normalmente e não toca em tela durante o atendimento.

Secundários: paciente (beneficiado pela atenção integral e pelo consentimento transparente) e instituição de saúde (controladora dos dados, beneficiada por registros completos, auditáveis e conformes à LGPD).

A.3 Walkthrough de uso

Fluxo principal

1. **Preparo (30s, única interação com o celular):** médico abre o companion, confere seu perfil (nome/CRM), digita o nome do paciente e registra os consentimentos — paciente, acompanhante (se presente) e, separadamente, autorização de CID em atestado. **Sem consentimento do paciente, o app se recusa a iniciar** (bloqueio em código).
2. Médico toca "Iniciar consulta", **guarda o celular** (tela pode ser bloqueada — a captura roda em Foreground Service com notificação persistente e neutra).
3. A consulta acontece **naturalmente**: o áudio flui dos óculos por Bluetooth HFP e é transcrito em tempo real no telefone (Vosk PT-BR, on-device), com timestamp por palavra.
4. Ao examinar uma lesão, o médico diz **"registrar imagem"** → a câmera dos óculos é ativada por poucos segundos e captura uma foto pontual (`capturePhoto()` do DAT durante um burst breve de stream), cifrada e vinculada à consulta → resposta por áudio: *"Imagem registrada"*.
5. Ao definir a conduta, diz **"emitir atestado de três dias"** → *"Atestado anotado"*.
6. Diz **"encerrar consulta"** → o telefone estrutura a transcrição em fatos com proveniência → rascunho SOAP → validação anti-alucinação → resposta por áudio: *"Consulta encerrada. Rascunho pronto com N fatos, X para revisar. Atestado de 3 dias aguardando revisão."*
7. **Entre consultas**, o médico abre a tela de revisão: vê S/O/A/P com cada fato apontando para o trecho do áudio ([20s–40s]), fatos incertos marcados, e o rascunho do atestado. **Edita, confirma ou descarta**. Na consulta simulada do protótipo, revisar o rascunho leva <1 min; a meta de produto é **revisão ≤ 10% da duração da consulta** (≤2 min para 20 min) — se a revisão custasse 10 min, o produto não devolveria tempo algum, por isso ela é métrica de aceitação. Só após a confirmação o rascunho vira base do registro oficial e o atestado vira PDF (hash auditado; assinatura física do médico — ICP-Brasil na fase 2).

Fluxos de exceção

Exceção	Comportamento
Paciente recusa	Captura não inicia; consulta segue normal sem o app
Óculos com bateria baixa / aquecimento / desconexão	Degradação automática em escada até o mic do celular, com avisos por áudio — detalhada em A.7.1; a consulta nunca é perdida
App morre (crash/OEM)	Perda máxima de 60s (chunks selados a cada minuto); a lacuna fica documentada no manifesto (gap de sequência) — juridicamente melhor que um registro "editado"
ASR incerto / termo não reconhecido	Fato marcado "incerto" ou campo "não informado" — o sistema nunca completa lacunas (testado: quando o ASR destruiu o CID falado, o atestado saiu corretamente sem CID)
Paciente pede exclusão (LGPD art. 18)	"Descartar consulta" apaga tudo; vídeo de segurança tem crypto-erasure (destruir as chaves torna o conteúdo irrecuperável)

A.4 Decisões técnicas (justificativa + alternativas descartadas)

#	Decisão	Justificativa	Alternativas descartadas
1	Áudio via Bluetooth HFP/SCO do Android (setCommunicationDevice), não pelo SDK	O DAT 0.9 não expõe microfone como API pública ; a própria documentação da Meta define o caminho suportado: sessões DAT "compartilham microfone e alto-falante com o stack Bluetooth do sistema", com guia oficial de ordenação (rota HFP estabilizada antes de iniciar o stream) — exatamente a ordem que implementamos	Esperar API de áudio do DAT (não existe); usar só o mic do celular (perde o mãos-livres — mantido apenas como fallback L4)
2	IA 100% on-device (ASR Vosk + pipeline no telefone)	Dado de saúde é sensível (LGPD art. 5º II, art. 11): zero conteúdo clínico em rede elimina a maior superfície de risco; funciona sem internet; latência previsível; demo em modo avião	ASR/LLM em nuvem (Whisper API, GPT): transferência de dado sensível, dependência de rede, custo por consulta, impossível demonstrar minimização equivalente
3	Câmera como evento : burst breve de stream + capturePhoto() por voz, sem stream contínuo como padrão	A captura de foto do DAT ocorre durante um stream ativo; ativamos o stream por poucos segundos apenas no comando de voz. Stream contínuo é evitado porque a coexistência HFP+stream varia por aparelho (issue pública #136: há handset validado com 5,5 min estáveis e handset com timeouts de GATT) e drena bateria	Vídeo contínuo como padrão (rejeitado pela análise LGPD de necessidade e pela AUP; sobrevive apenas como modo blindado opcional , desligado por padrão)
4	Pipeline em 2 estágios: extração factual → classificação SOAP , com proveniência obrigatória por fato e validador de alucinação (unsupported-statement-rate)	Reduz a liberdade generativa a zero no MVP: fato sem origem no áudio não compila (invariante no modelo de dados); a métrica torna a alucinação mensurável	"LLM escreve o prontuário" em um passo (alucinação não mensurável, inaceitável em documento clínico)

5	Classificador heurístico agora; LLM local (Gemma 3n) na fase 2 atrás da mesma interface	Heurística tem zero alucinação por construção e roda em qualquer aparelho; a interface FactExtractor permite trocar pelo LLM após benchmark de RAM/latência no hardware real	Muse Glimmer on-device (30B ≈ 17–20 GB — não cabe em smartphone; avaliado e descartado); LLM em nuvem (decisão #2)
6	Cofre por envelope: DEK AES-GCM por chunk de 60s, KEK no Android Keystore; AAD amarra chunk à consulta	Perda máxima de 60s em falha; chunk não pode ser transplantado entre consultas (verificado por teste criptográfico); chave-mestra não exportável	Cifrar o arquivo inteiro no fim (perde tudo em crash); armazenar em servidor próprio (reintroduz nuvem)
7	Modo blindado do vídeo (opcional): DEK embrulhada somente na chave pública do custodiante institucional; abertura só com a chave privada, mediante ordem judicial	Proteção médico-legal com garantia técnica: nem o médico consegue assistir (validado ponta a ponta: decifra externa com a chave do custodiante funciona; local é impossível). Sem chave configurada, vídeo não grava	Vídeo decifrável no aparelho (risco de uso indevido); gravação sem consentimento específico (vetado pela análise LGPD)
8	Foreground Service <code>microphone connectedDevice</code> , iniciado com Activity visível	Exigência do Android 14+ para FGS de microfone; sobrevive a tela bloqueada/background (testado)	WorkManager/serviço comum (morto pelo sistema); manter Activity aberta (péssima UX mãos-livres)
9	Desenvolvimento contra gateway próprio (DeviceGateway) + MockDeviceKit	Hardware real só existe no dia do hackathon; a abstração isola o SDK em preview (que muda a cada versão) e permitiu validar todo o pipeline em emulador antes de tocar nos óculos	Desenvolver direto contra o DAT só no dia (risco integral concentrado em 1 dia)
10	SOAP como estrutura operacional; FHIR como camada futura	SOAP é o padrão cognitivo do médico brasileiro; FHIR entra na integração com sistemas (fase 2) sem retrabalho do modelo	FHIR nativo desde o MVP (complexidade sem valor demonstrável no hackathon)
11	Atestado por voz com guardrails CFM (Res. 1.658/2002): dias/CID nunca inferidos; CID exige consentimento específico; documento só após confirmação	Mesmo princípio anti-alucinação aplicado a documento legal; testado com ASR degradado (extraiu dias corretos e recusou-se a inventar CID)	Receita médica no MVP (regulação de prescrição eletrônica exige assinatura qualificada — fica como roadmap)

A.5 Concorrentes e diferenciação

Concorrente	O que faz	Por que somos diferentes
Nuance DAX Copilot (Microsoft)	Ambient scribe líder global; grava a consulta pelo celular/sala e gera nota clínica na nuvem Azure	Nuvem (dado sai do consultório), inglês-primeiro, custo de assinatura alto, sem mãos-livres real nem captura visual
Abridge / Suki	Scribes ambient por app de celular, nuvem	Mesmas limitações: nuvem + telefone sobre a mesa; nenhum usa o ponto de vista do médico
Amazon HealthScribe	API de transcrição/sumarização clínica (AWS)	É infraestrutura de nuvem para terceiros — o oposto do nosso desenho de minimização
Voa Health (Brasil)	Scribe ambient PT-BR via celular, processamento em nuvem	PT-BR nativo como nós, mas nuvem e sem hardware vestível
Prontuários eletrônicos BR (iClinic, Feegow etc.)	Registro manual/dictation	Não resolvem a captura ambient; são o destino futuro da nossa exportação (FHIR)

Nossa combinação é inédita: (1) óculos = mãos 100% livres + câmera no ponto de vista do médico; (2) **zero nuvem** — único da categoria demonstrável em modo avião; (3) rastreabilidade fato-a-fato com métrica de alucinação; (4) modo blindado com garantia criptográfica para proteção médico-legal; (5) atestado por comando de voz com guardrails do CFM.

A.6 Os cinco pilares técnicos obrigatórios

1. Uso de IA (funcional e comprovável)

ASR streaming PT-BR on-device (Vosk, timestamps por palavra) + pipeline de estruturação clínica: extração factual → classificação SOAP → **validador de proveniência** que mede o percentual de afirmações sem suporte na transcrição. Importância da métrica bem enquadrada: no MVP heurístico ela é **0% por construção** (o classificador só reorganiza fatos, não gera texto) — seu papel real é **gatear a adoção do LLM local (Gemma 3n) na fase 2**, que só substitui a heurística se mantiver a taxa $\leq 2\%$ no mesmo corpus. **Qualidade do ASR, com honestidade:** WER formal ainda não medido (exige celular físico — protocolo pronto: corpus PT-BR médico, WER/CER + acurácia de entidades críticas). Resultado qualitativo já observado: com o modelo small, linguagem geral é fiel, mas **fármacos e doses degradam** ("dipirona quinhentos miligramas" saiu irreconhecível) — por isso o desenho marca entidades incertas para revisão em vez de confiar no ASR, e o plano prevê modelo maior + boost de vocabulário médico, com meta de **acurácia $\geq 95\%$ em entidades críticas** (fármaco, dose, pressão) antes de qualquer piloto real. Detecção de comandos de voz roda sobre os parciais do ASR com prefixos tolerantes a erro (testado: "emitir" → "admitir" não quebrou o comando). *Comprovável: o protótipo executa tudo isso em emulador Android, com consulta simulada de ponta a ponta.*

2. Câmera ou microfone como entrada principal

Microfone dos óculos é o canal primário — pelo caminho definido na documentação oficial da Meta ("Use device microphones and speakers"): HFP pelo stack Bluetooth do sistema, com o nosso código de rota

idêntico ao exemplo oficial Android (`MODE_IN_COMMUNICATION` + `setCommunicationDevice(TYPE_BLUETOOTH_SCO)`), áudio 8 kHz mono conforme a spec, e a ordenação oficial respeitada (rota estabilizada antes do stream). Ressalva honesta que vamos testar no hackathon: em HFP o beamforming dos óculos prioriza a voz de quem os veste — se a voz do paciente chegar fraca, o desenho prevê o mic do telefone como captura de sala (nível L4 da escada, já implementado), mantendo óculos para TTS e câmera. **Câmera** via DAT 0.9 (`DeviceSession.addCamera` → burst breve de stream + `capturePhoto()`) acionada por comando de voz para evidência visual pontual — desenho deliberado de "câmera como evento" pelas limitações verificadas do stream (resolução 720p máx., FOV ~53°, coexistência com HFP dependente do aparelho).

3. Saída por áudio

Toda a interação durante a consulta é falada (TTS PT-BR): confirmações curtas (*"Imagem registrada"*, *"Atestado anotado"*), avisos da escada de energia (*"Modo de economia nível L2"*), fallbacks (*"Óculos não encontrados, usando microfone do telefone"*) e o resumo final com pendências. Desenho não-intrusivo: frases de 1 linha, nunca áudio contínuo.

4. Privacidade e dados

Dado de saúde = sensível (LGPD art. 5º, II; art. 11 — base legal: tutela da saúde + consentimento destacado como salvaguarda). Medidas implementadas: consentimento **bloqueante** (paciente, acompanhante e CID separados); processamento 100% local — **o app sequer declara a permissão INTERNET no manifest**, sendo incapaz de rede por construção (demonstrável em modo avião); cifra AES-GCM por chunk com chave no Keystore; telemetria e crash-reporting do SDK **desligados** (`ANALYTICS_OPT_OUT` , `CRASH_REPORTING_OPT_OUT`); notificação persistente sem conteúdo clínico; auditoria append-only hash-encadeada (adulteração detectável); revisão humana obrigatória antes de qualquer registro; direito de eliminação por descarte total e **crypto-erasure**; vídeo de segurança (opcional, OFF por padrão) indecifrável no aparelho — só custodiante institucional com ordem judicial.

5. Eficiência de bateria

Estratégia em três frentes, instrumentada: (a) **os óculos só trabalham quando necessário** — mic contínuo é inevitável (é o produto), mas câmera é por evento e vídeo opcional roda a 360p@7fps; (b) **degradação automática em escada** dirigida pelos sinais tipados do DAT (detalhada em A.7.1); (c) **IA pesada roda no telefone**, nunca nos óculos, e a estruturação ocorre uma única vez ao encerrar. Telemetria de bateria auditada por consulta; modelo operacional completo de energia (turnos, case, checklist) em A.7.1.

A.7 Precauções e plano de contingência

A.7.1 Energia — modelo operacional "por turnos de consulta"

O erro clássico de wearable clínico é planejar como se a bateria fosse infinita. Nós invertemos: **o dia de trabalho é dividido em ciclos consulta ⇌ recarga**, apoiados nos números oficiais do hardware:

Fato (fonte: Meta, ficha oficial Gen 2)	Valor
Uso misto	até 8 h
Áudio contínuo (nosso perfil dominante)	~5 h
Case carregador	+48 h de cargas
Fast charge no case	50% em ~20 min

Carregamento	somente via case (sem porta nos óculos)
--------------	---

Matemática do turno: uma consulta típica de 20–30 min em nosso perfil (HFP contínuo + fotos pontuais + TTS eventual) consome, por estimativa conservadora sobre os ~~5 h de áudio contínuo, **~~7–10% da bateria**. Entre consultas há tipicamente 5–15 min de intervalo administrativo — janela em que os óculos **voltam ao case** (fast charge repõe ~2,5% por minuto). Resultado: em regime estacionário, o conjunto óculos+case sustenta um turno de 8–12 h de atendimentos **sem tomada**, porque o case funciona como a "bateria externa" de 48 h que acompanha o médico.

Precauções em camadas:

1. **Pré-voe (checklist no companion antes de cada consulta):** % dos óculos, % do case, % do telefone, rota BT ativa, modelo ASR carregado. Abaixo de 20% nos óculos, o app recomenda iniciar já em modo áudio-somente (L2).
2. **Durante:** escada de degradação L0→L4 automática guiada pelos erros tipados do DAT (BATTERY_CRITICAL , PEAK_POWER_SHUTDOWN , THERMAL_*) e ThermalLevel — corta primeiro vídeo, depois câmera, por último a rota BT; **o áudio clínico é o último a cair e a consulta nunca é perdida** (fallback final: mic do telefone).
3. **Entre consultas:** óculos no case (turno de recarga); o companion exibe a projeção "quantas consultas cabem na carga atual".
4. **Telefone:** ao contrário dos óculos, opera carregando — em consultório fica em powerbank/tomada; o custo pesado (ASR/LLM) roda nele exatamente por isso.
5. **Telemetria auditada:** % de bateria no início/fim de cada consulta entra no log de auditoria — em campo, o modelo estimado é substituído por dados reais do próprio uso.
6. **Instituições com volume alto:** recomendação de 2º par de óculos em rodízio pelo case (custo marginal baixo frente ao ganho de disponibilidade).

A.7.2 Privacidade e segurança — modelo de ameaças

Além do desenho preventivo (pilar 4), mapeamos ameaças concretas e o controle que responde a cada uma:

Ameaça	Controle implementado
Perda/roubo do celular do médico	Dados em filesDir privado, cifrados AES-GCM com chaves no Android Keystore (não-exportáveis, hardware-backed); vídeo blindado nem existe em forma decifrável
App malicioso no mesmo aparelho	Sandbox Android + arquivos no diretório privado + app sem permissão INTERNET (exfiltração pelo nosso processo é impossível por construção)
Coação/curiosidade sobre o vídeo de segurança	Modo blindado: nem o médico, nem o app, nem perícia no aparelho decifram — só a chave privada do custodiante, mediante ordem judicial
Adulteração de prontuário/atestado a posteriori	Log de auditoria hash-encadeado + cadeia de custódia sha256 por chunk: qualquer alteração quebra a cadeia de forma detectável
Vazamento por tela/notificação	Notificação do serviço é neutra (sem nome de paciente); revisão exige abrir o app
Telemetria de SDK	ANALYTICS_OPT_OUT + CRASH_REPORTING_OPT_OUT ativos

Captura de terceiros incidentais	Consentimento de acompanhante obrigatório; aviso de ambiente; direito de eliminação com crypto-erasure
Gravação encoberta (AUP da Meta)	Impossível no desenho: consentimento bloqueante em código + notificação persistente + LED nativo dos óculos + anúncios por TTS
AUP — "locais sensíveis" : a Acceptable Use Policy veda encorajar gravação em locais sensíveis, e consultório médico é candidato óbvio	Risco declarado, não escondido. Nossa interpretação: a vedação mira captura encoberta/indiscriminada; aqui a gravação é iniciada pelo profissional responsável pelo ambiente, com consentimento explícito e registrado de todos os presentes, transparência ativa (LED + notificação + TTS) e finalidade legítima de documentação clínica. Buscaremos confirmação formal dessa interpretação com os mentores Meta antes do hackathon ; se negativa, o produto opera sem armazenar mídia bruta (só transcrição), preservando o valor central
Perda da chave do custodiante	Procedimento de custódia com cópias redundantes lacradas; perda degrada apenas o vídeo opcional — áudio clínico e prontuário não dependem dela

A.7.3 Continuidade da consulta — o que acontece quando algo falha

Falha	Comportamento (implementado e testado em emulador)
Óculos desconectam / bateria acaba	Fallback automático para mic do telefone com aviso por TTS; consulta continua
App morre (crash, OEM battery saver)	Perda máxima de 60 s (chunks selados por minuto); lacuna documentada no manifesto; temporários órfãos descartados no retorno
ASR indisponível (modelo não instalado)	Captura continua (áudio cifrado íntegro); transcrição pode ser reprocessada depois
Coexistência mic+câmera instável no aparelho	Escada L2: câmera sai, áudio fica — decidido automaticamente no primeiro sinal de erro de stream
Termos médicos não reconhecidos	Fato marcado "incerto" para revisão — nunca preenchido por inferência

Princípio unificador: **nenhuma falha de tecnologia pode custar a consulta nem inventar conteúdo clínico** — degradar é aceitável, perder ou alucinar não.

Status de validação (transparência técnica)

Validado em protótipo funcional (emulador + 52 testes automatizados)	Pendente de hardware real (protocolo pronto)
Pipeline completo fala→SOAP→cofre→revisão; foto e atestado por voz; modo blindado com decifra externa; escada de energia;	Captura do mic dos óculos via HFP — nosso código é idêntico ao exemplo oficial da documentação da Meta, mas só validaremos nós mesmos no hardware; beamforming em HFP prioriza a voz do médico (docs

background/tela bloqueada; recuperação de crash; consentimento bloqueante

oficiais) — medir a captação do paciente e, se preciso, usar o mic do telefone como captura de sala (fallback já implementado); coexistência HFP+câmera no aparelho fornecido (go/no-go na 1ª hora); curva de bateria dos óculos; ASR com HFP real (piso 8 kHz já medido em simulação = spec oficial); FOV de enquadramento